#### #2022 서울시립대학교 AICOSS

## 기업 연계형 실습 중심의 딥러닝 부트캠프

D조 김다은,김민주,방승현,조형진,최도윤

# Rexsoft



### 목차

A table of Contents

#1 문제 정의 #2 데이터셋 소개 및 사용방안 #3 선택한 모형 #4 결과

## 문제 정의

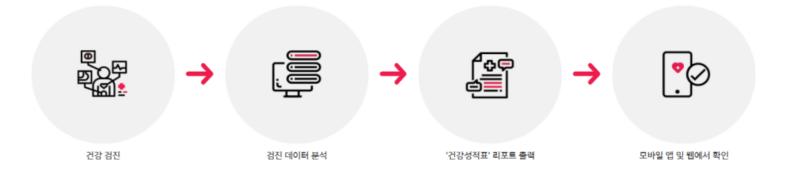
### 문제 정의

#### 건강성적표

"건강성적표로 <mark>건강 상태를 한눈에</mark> 살펴볼 수 있습니다."

건강성적표는 여러 기관의 건강 검진 데이터, 건강보험공단 등의 자료를 활용하여 고객의 건강한 정도, 기대 수명, 노화 정도, 질환 발생 위험도를 고객의 성별 및 연령에 따라 맞춤형으로 평가해주는 서비스입니다.

> '건강성적표'는 검진 결과를 성적표 형식으로 구성하고 분석하여, 의학 전문 지식이 없는 일반 소비자도 쉽게 이해할 수 있습니다.

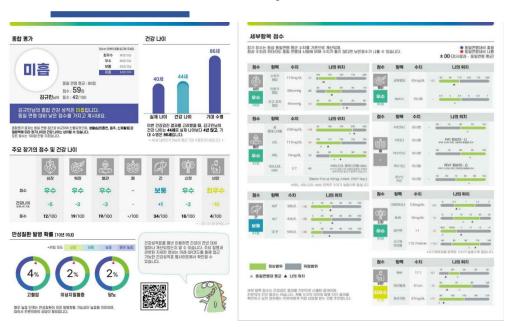


Rexsoft 미연계 기관에서 받은 검진 결과로도 건강성적표를 출력해보면 어떨까?

## 데이터셋 소개 및 사용방안

### 데이터셋 소개 및 사용방안

#### **⟨PDF template⟩**



#### 〈가정〉

실제 수검자는 이 PDF를 A4 용지에 출력한 결과지를 소지하고 있다고 가정

결과지를 핸드폰 카메라로 찍어서, 웹 또는 어플에 업로드하여 전달하는 것을 가정

미연계 기관의 경우, 해당 기관에서 제공하는 서식에 맞춘 결과지 가 제공되나, 현재는 예시로 제공된 하나의 서식만 있다고 가정

### 선택한 모형 -Easy OCR-

#### OCR

#### 광학 문자 인식(OCR)이란 무엇인가?

광학 문자 인식(OCR)은 텍스트 이미지를 기계가 읽을 수 있는 텍스트 포맷을 변환하는 과정 OCR을 사용하면 이미지를 텍스트 데이터로 저장 가능



전처리

- 컬러 이미지를 먼저 회색조로 변환
- 밝기와 명암 대비

글자 검출

• 딥러닝 시스템을 이용하여 전체 이미지에서 텍스트인 영역을 골라내는 작업을 수행

글자 인식

 글자를 구분하는 여러 특징을 대량의 데이터 를 통해 컴퓨터가 학습 및 추출

후처리

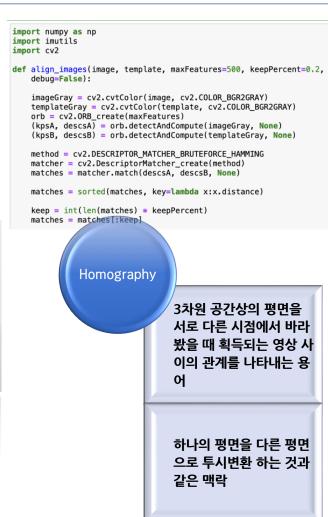
• 출력된 텍스트에 부자연스러운 단어나 문자가 포함되면 이를 수정하여 정확도 향상

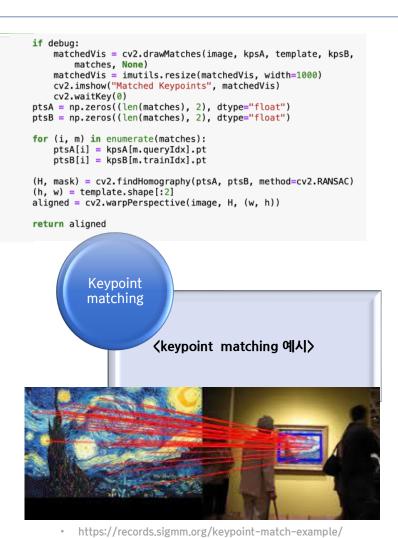
### **EasyOCR**

#### 데이터 전처리

#### (alignment process)







#### 데이터 전처리



#### 왜 "ROI(Region Of Interest)"를 사용해야 하는가?

Easyocr을 활용하여 건강성적표 전체를 읽어내는 것은 어려움. 따라서 cv2.selectROI 를 사용하여 엑셀 값에 정리할 숫자들만 추출하여 ocr을 진행하는 것이 효과적

```
##영역구하기

#마우스 드래그로 영역구하는 함수

def get_pos(img,start,end):
    idx = list(range(start,end+1))
    positions = []
    for i in range(start,end+1):
        x1,y1,width,height = cv2.selectROI("location",img,False)
        x2 = x1+width
        y2 = y1+width
        positions.append([x1,y1,x2,y2])

cv2.destroyAllWindows()
    return idx,positions
```

#### **OCR**

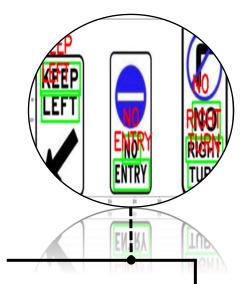




- 글자들이 존재하는 위치를 찾아내고 이를 bounding box로 묶음
- bounding box로 묶인 글자들은 인식 모델의 입력으로 들어감
- Text Detection 은 주로 CNN계열의 모델을 사용

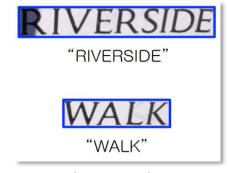


- bounding box 안 글자가 어떤 내용인지 알아냄
- Text Recognition은 주로 RNN 계열의 모델을 사용





〈글자 검출〉



〈글자 인식〉

https://cvml.tistory.com/16

#### 후처리

1

```
for i in range(len(km)):
    if km[i] == '':
        km[i] = 'nan'

# km이라는 리스트 안에 있는 원소가 ''이면 'nan'으로 대체
```

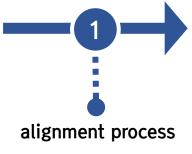
2

3

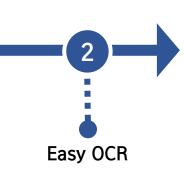


#### **OCR**









1		항목	텍스트	
2	0	이름	김혜수	
3	1	성별	여자	
4	2	나이	35	
5	3	공복혈당	97mgldL	
6	4	사구체여과율	113 8rnVmin	
7	5	요단백(정상/악양성/+1/+2/+3/+4)	의양성	
8	6	중성지방	43mgldL	
9	7	총콜레스테롤	215mg/dL	
10	8	최고-최저 혈압	37mmia	
11	9	수축기혈압	io3mgldL	
12	10	이완기혈압	66mmkg	
13	11	크레아티닌	O.bmgldL	
14	12	허리둘레	62cmn	
15	13	HbA1c	5.49a	
16	14	ALT	22IJNL	
17	15	AST	22U/	
18	16	BMI	19	
19	17	FEV1/FVC	미시행	
20	18	FEV1(L)	미시행	
21	19	FEV1(%)	미시행	
22	20	FVC(%)	미시행	
23	21	FVC(L)	미시행	

〈원본 사진〉

〈이미지 변환 후〉

〈OCR 적용 후〉

#### **OCR**

	Α	В	С	
1		항목	텍스트	
2	0	이름	김혜수	
3	1	성별	여자	
4	2	나이	35	
5	3	공복혈당	97mgldL	
6	4	사구체여과율	113 8rnVmin	
7	5	요단백(정상/악양성/+1/+2/+3/+4)	의양성	
8	6	중성지방	43mgldL	
9	7	총콜레스테롤	215mg/dL	
10	8	최고-최저 혈압	37mmia	
11	9	수축기혈압	io3mgldL	
12	10	이완기혈압	66mmkg	
13	11	크레아티닌	O.bmgldL	
14	12	허리둘레	62cmn	
15	13	HbA1c	5.49a	
16	14	ALT	22IJNL	
17	15	AST	22U/	
18	16	ВМІ	19	
19	17	FEV1/FVC	미시행	
20	18	FEV1(L)	미시행	
21	19	FEV1(%)	미시행	
22	20	FVC(%)	미시행	
23	21	FVC(L)	미시행	

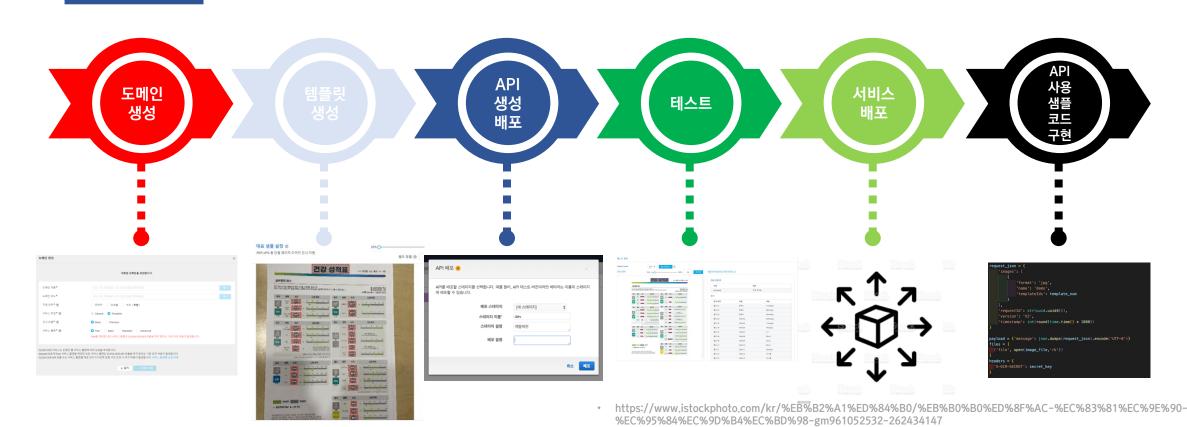


	Α	В	С	D	Е	F	G
1	순번	항목	01 김규민 1/25	02 김은경 6/25	09 한정연 5/25	04 안수진 7/25	03 김혜수 4/25
2	1	이름	0	0	0	0	0
3	2	성별	0	0		0	0
4	3	나이	0	0	0	0	o
14	13	공복혈당	0		0	0	o
15	14	사구체여과율	0		0		o
16	15	요단백 (정상/약양성/+1/+2/+3/+4)					
17	16	중성지방	0	0	0		
18	17	총콜레스테롤	0	0	0	0	o
19	18	최고-최저 혈압	0	0	0	0	o
20	19	수축기혈압	0	0	0	0	
21	20	이완기혈압	0	0	0	0	0
22	21	크레아티닌	0	0	0		0
	22	허리둘레	0		0		0
24		HbA1c	0	0	0	0	0
25		ALT	0			0	
26		AST	0	0		0	0
27	26	BMI	0		0		0
28	27	FEV1 / FVC	0	0	0	0	0
29	28	FEV1 (L)	0	0	0	0	0
30		FEV1 (%)	0	0	0	0	0
31	30	FVC (%)	0	0	0	0	0
32	31	FVC (L)	0	0	0	0	0
33	32	GTP	0	0			0
34	33	HDL	0	0	0	0	0

### 선택한 모형 -Clova Al-

### Clova AI

#### How to install



### Clova Al

```
response = requests.request("POST", api_url, headers=headers, data = payload, files = files)

res = json.loads(response.text.encode('utf8'))
df = pd.json_normalize(res)
df = df['images'][0][0]['fields']

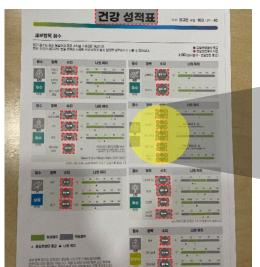
data = list()
column_name = list()
for i in range(len(df)):
    data.append(df[i]['inferText'])
    column_name.append(df[i]['name"])

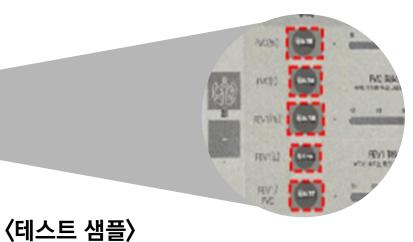
df = pd.DataFrame(data)
df = df.transpose()
df.columns = column_name

if not os.path.exists('/Users/doyunchoi/Desktop/test_6.csv'):
    df.to_csv('/Users/doyunchoi/Desktop/test_6.csv', mode='w', encoding='utf-8-sig')
else:
    df.to_csv('/Users/doyunchoi/Desktop/test_6.csv', mode='a', encoding='utf-8-sig', header=False)
```

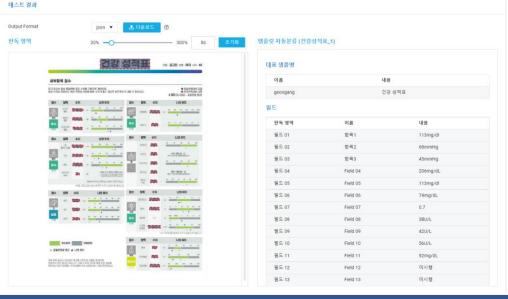
#### 이완기혈압 최고-최저혈압 총콜레스테롤 LDL HDL **AST** ALT 206mg/dL 113mg/dL 68mmHg 45mmHg 113mg/dL 74mg/dL 38IU/L 42IU/L 113mg/dL | 74mg/dL | 38IU/L 113mg/dL 68mmHg 45mmHg 206mg/dL 42IU/L FEV FEV1\_PVC 크레아티닌 BUN GTP HbA1c PVC PVC\_L PEV 92mg/dL 미시행 미시행 미시행 미시행 미시행 미시행 0.6mg/dL | 16mg/dL 56IU/L 92mg/dL 미시행 미시행 미시행 미시행 미시행 미시행 0.6mg/dL 16mg/dL 56IU/L

#### unchoi/Desktop/test\_6.csv',mode='a', encoding='utf-8-sig', header=False) <결과〉





〈소스 코드〉

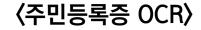


추가 내용

### 추가 내용



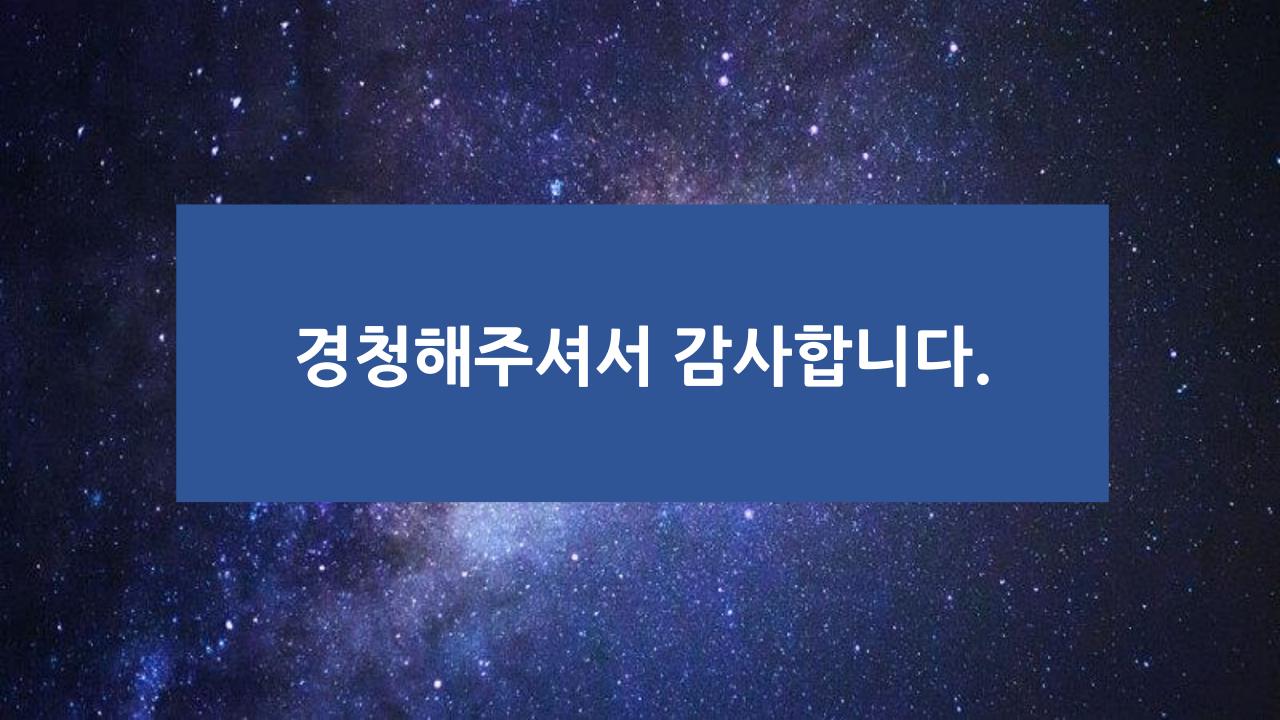
https://blog.naver.com/PostView.nhn?blogId=inzisoft&logNo=222356106818





https://kor.pngtree.com/freepng/document-icon-for-your-project\_4812896.html

〈다른 템플릿〉



# Q&A